

第1章 人工智慧實務應用與大數據簡介

大數據分析

- R/Python/Julia/SQL程式設計與應用
(R/Python/Julia/SQL Programming and Application)
- 資料視覺化 (Data Visualization)
- 機器學習 (Machine Learning)
- 統計品管 (Statistical Quality Control)
- 最佳化 (Optimization)



李明昌博士

<https://www.youtube.com/@alan9956>

<http://rwepa.blogspot.com/>

alan9956@gmail.com

大綱

- 1.人工智慧發展
- 2.大數據簡介
- 3.資料面面觀
- 4.資料生命週期管理
- 5.資料剖析、解譯與洞察力

RWEPA簡介: <http://rwepa.blogspot.com/>


- 姓名：李明昌 (ALAN LEE)
- 現職：中華智慧決策與控制學會 (中華R軟體學會) 理事
臺灣資料科學與商業應用協會 理事
- 學歷：中原大學 工業與系統工程所 博士
- 經歷：
 - 淡江大學 兼任教師
 - 育達科技大學 兼任教師
 - 佛光大學 兼任教師
 - 國立台北商業大學 兼任教師
 - 東吳大學 兼任教師
 - 育達科技大學 資訊管理系(所) 專任助理教授
 - 崇友實業 行銷企劃專員
 - 國航船務代理股份有限公司 海運市場運籌管理員
- 大專院校、資策會、工業技術研究院、國家發展委員會、中央氣象局、公平交易委員會、衛生福利部、縣市政府與日本名古屋產業大學等公民營單位演講達366場，3477小時。
- 連絡資訊：alan9956@gmail.com




- iPAS AI應用規劃師 證照推廣
- iPAS 營運智慧分析師 證照推廣

1.人工智慧發展

人工智慧發展



人工智慧發展



- 1943年：美國數學家 Walter Pitts和心理學家 Warren McCulloch提出人工神經元。
- 1957年：美國心理學家 Frank Rosenblatt 提出了感知器(Perceptron)。
- 1980年：多層類神經網路失敗，淺層機器學習方法(SVM等)興起。
- 2006年：Geoffrey Hinton 成功訓練多層神經網路(限制玻爾茲曼機, RBM)，命名為深度學習。
- 2012年：ImageNet 比賽讓深度學習重回學界視野，開啟 NVIDIA GPU 成為重要運算硬體 (NVDA, \$138.99/股)。
- 2013年：變分自編碼器 (Variational Autoencoder, VAE), GAN, LSTM, RNN, Diffusion, Transformers (GPT)

機器學習 Machine learning

- 非監督式學習 (Unsupervised learning)
 - No label or target value given for the data
 - 監督式學習 (Supervised learning)
 - Telling the algorithm what to predict
 - 半監督學習 (Semi-supervised learning)
 - 具有少量標記資料
 - 強化學習 (Reinforcement learning)
 - 為了達成目標，隨著環境的變動，而逐步調整其行為，並評估每一個行動之後所到的回饋是正向的或負向的。
 - 深度學習 (Deep learning)
- 

監督式學習 vs. 非監督式學習

- 非監督式學習 Unsupervised learning
 - 集群法 Clustering, <https://youtu.be/0UJbhVWDuI4>
 - 關聯規則 Association rule, <https://youtu.be/rh5GxJamtNg>
 - 主成分分析 Principal Component Analysis
- 監督式學習 Supervised learning (執行 $X \rightarrow Y$): 分類與數值預測
 - 迴歸分析 Regression analysis, https://youtu.be/i5_urp8XzEs
 - 廣義線性模型 General linear model (GLM)
 - 天真貝氏法 Naïve-Bayes
 - K近鄰法 k-nearest neighbors (KNN)
 - 決策樹 Decision tree
 - 支持向量機 Support vector machine (SVM)
 - 類神經網路 Neural network (NN)
 - 集成學習 Ensemble learning: 使用多種學習算法來獲得比單獨使用演算法更好預測結果

2.大數據簡介

大數據 (Big data)

- 大數據表示資料規模龐大、生成速度極快、且類型錯綜複雜的數據集合。
- 這些數據因為太過龐大，傳統的 Excel 試算表或單機資料庫（如早期的 SQL 系統）根本無法在合理的時間內完成處理或分析。

大數據 – 5V

大數據核心特徵：5V 模型 (5 Vs of Big Data Core Characteristics)

1. 大量 (Volume)



- 規模龐大、海量
- 從 TB 跳升到 PB、EB
- 全球社交媒體貼文、點擊流

2. 高速 (Velocity)



- 生成與處理速度極快
- 即時或接近即時處理
- 金融交易、IoT 感測器數據

3. 多樣 (Variety)



- 格式錯綜複雜
- 結構化、半結構化、非結構化
- 影片、郵件、網頁日誌

4. 真實性 (Veracity)



- 數據準確性與可信度
- 清洗雜訊與異常值
- 高質量數據篩選

5. 價值 (Value)



- 商業或預測價值
- 低價值密度淘金
- 機器學習分析決策

3.資料面面觀

資料類型

- 結構化資料 (Structured data)

- 量化資料
- 資料模型已經事先定義，彈性較少
- 資料格式較有限制
- 較適用於進行資料分析 (例: Machine Learning)
- 有限的儲存方式，例: 關聯式資料庫

- 非結構化資料 (Unstructured data)


- 非量化資料 (網頁, 照片, 語音)
- 資料模型無事先定義，彈性較大
- 資料格式較無限制
- 較難直接使用現有套裝軟體分析(例:自然語言處理, NLP)
- 可以使用 NoSQL 儲存 (例: MongoDB, Hadoop)

- 半結構化資料 (semi-structured data)

- 範例: JSON, XML, CSV
- 使用元資料(metadata)註記資料特性

資料類型 (續)

- 時間序列資料: 按照時間發生先後順序進行排列的資料序列。
 - 趨勢
 - 季節性/週期性
 - 殘差
- 地理資料: 經度、緯度、行政區域、國家。
 - 主題式地圖 (Thematic map)
 - <https://rwepa.blogspot.com/2018/10/thematicmap.html>



資料應用


- 更深層了解客戶需求，提供更佳客戶服務 (訂定 KPI)
- 建立更有客製化的行銷活動
- 追蹤當前指標並建立新指標
- 創造更佳的产品機會和服務
- 增加營運收入
- 降低營運成本
- 創造資料附加價值

Value


4.資料生命週期管理

資料生命週期管理

- 資料生命週期管理 (**Data Lifecycle Management, DLM**)。
- 從資料的建立到資料的銷毀, DLM包括六大步驟。
- 人員、流程、技術三大層面→ 資料治理 (Data Governance)。



Eryurek, E., Gilad, U., Lakshmanan, V., Kibunguchy-Grant, A., & Ashdown, J., *Data Governance: The Definitive Guide: People, Processes, and Tools to Operationalize Data Trustworthiness*, O'Reilly Media, 2021. [[LINK](#)]



1.資料的建立

- 結構化、非結構化、半結構化資料
- 資料產生的頻率: 批次、串流
- 資料與元資料
- 資料歷程 (Lineage)
- 資料建立來源(第三方、企業內部輸入)
- 資料捕獲(POS、生產線機台、物聯網感測器)

2.資料的處理

- 資料整合 (Data Integration)
 - 整合不同資料來源為單一標準資料。
- 資料清理 (Data Cleaning)
 - 辨識**不正確、不完整、不相關、重複值、或格式錯誤資料**，然後進行取代、修改或刪除髒資料。
- ETL運用 (Extract, Transform, Load)
 - ETL表示將資料從來源端經過抽取 (extract)、轉置 (transform)、載入 (load) 至目的端的過程。
- 資料歷程 (Lineage)
 - 整個生命週期中的「來源 → 轉換 → 使用 → 輸出」, 包括更新**時間與版本**。
- 資料的分類(敏感性，重要性)
- 資料品質
 - 資料是否正確、完整、一致、可信且適合使用。
- 手動、自動化、半自動資料的處理

3.資料的儲存

- 具有保護級別的儲存設備
- 加密
- 備份
- 災難復原計畫 (Disaster Recovery Plan)

4.資料的使用

- 支援企業目標與營運
- 呈現資料的價值
- 篩選、報表、視覺化、儀表板、自動生成 Excel, Word, HTML等
- 商業智慧 (Business Intelligence, BI)
- 營運智慧 (Operational Intelligence, OI)

商業智慧 vs. 營運智慧



特性	商業智慧 BI	營運智慧 OI
功能	執行查詢並視覺化數據	監測和調查營運數據
資料	歷史數據分析	即時數據監控和警報
指標	收入、利潤和其它關鍵績效指標	營運業務的預測性指標
過程	被動反應的過程(reactive)	主動(proactive)預測應用
使用時機	BI涉及內部系統和外部來源的資料收集，以作為分析、特定查詢、報表和構建儀表板及資料視覺化的準備	OI的應用包括預測性維護即時產品和促銷推薦，例計算物流車輛的最佳運送路線

5.資料的歸檔

- 考慮不再使用、不再發佈更新的資料，最後將資料加以儲存。
- 已歸檔的資料較不用明確訂定復原流程與復原計畫。
- 資料保留策略，儲存時間長度。

6.資料的銷毀


- 刪除資料與相關副本
- 不考慮永久保存資料
- 符合相關法規
 - 金融機構防制洗錢辦法: 金融機構對國內外交易之所有必要紀錄，應至少保存五年。但法律另有較長保存期間規定者，從其規定。

開放資料

- <https://rwepa.blogspot.com/2019/09/dataset.html>
- DataDemo 下載
 - <https://github.com/rwepa/DataDemo>
- 政府資料開放平台
 - <https://data.gov.tw/>
- UCI Machine Learning Repository
 - <https://archive.ics.uci.edu/datasets>
- Google Dataset Search
 - <https://datasetsearch.research.google.com/>
- Kaggle Dataset
 - <https://www.kaggle.com/datasets>
- World Bank Open Data
 - <https://data.worldbank.org/>
- AI生成資料集, 範例 ChatGPT
 - <https://chatgpt.com/>

RWEPA 搜尋此網誌 (例: task)

現代資料科學家 (Modern Data Scientist) 四項技能




4. 溝通與視覺化

參考: <https://towardsdatascience.com/a-long-term-data-science-roadmap-which-wont-help-you-become-an-expert-in-only-several-months-4436733e63ff>

空氣品質小時值_新北市_淡水站

- <https://data.gov.tw/dataset/34759>

	A	B	C	D	E	F	G	H	I
1	siteid	sitename	county	itemid	itemname	itemengname	itemunit	monitordate	concentration
2	10	淡水	新北市	33	細懸浮微粒	PM2.5	μg/m3	2024/6/22 08:00	7
3	10	淡水	新北市	7	二氧化氮	NO2	ppb	2024/6/22 08:00	6.7
4	10	淡水	新北市	4	懸浮微粒	PM10	μg/m3	2024/6/22 08:00	22
5	10	淡水	新北市	3	臭氧	O3	ppb	2024/6/22 08:00	30.5
6	10	淡水	新北市	2	一氧化碳	CO	ppm	2024/6/22 08:00	0.2
7	10	淡水	新北市	1	二氧化硫	SO2	ppb	2024/6/22 08:00	1.1
8	10	淡水	新北市	33	細懸浮微粒	PM2.5	μg/m3	2024/6/22 07:00	9
9	10	淡水	新北市	7	二氧化氮	NO2	ppb	2024/6/22 07:00	8.9
10	10	淡水	新北市	4	懸浮微粒	PM10	μg/m3	2024/6/22 07:00	28
11	10	淡水	新北市	3	臭氧	O3	ppb	2024/6/22 07:00	16.5
12	10	淡水	新北市	2	一氧化碳	CO	ppm	2024/6/22 07:00	0.28
13	10	淡水	新北市	1	二氧化硫	SO2	ppb	2024/6/22 07:00	0.6
14	10	淡水	新北市	33	細懸浮微粒	PM2.5	μg/m3	2024/6/22 06:00	14
15	10	淡水	新北市	7	二氧化氮	NO2	ppb	2024/6/22 06:00	9.6
16	10	淡水	新北市	4	懸浮微粒	PM10	μg/m3	2024/6/22 06:00	27
17	10	淡水	新北市	3	臭氧	O3	ppb	2024/6/22 06:00	6.5
18	10	淡水	新北市	2	一氧化碳	CO	ppm	2024/6/22 06:00	0.37
19	10	淡水	新北市	1	二氧化硫	SO2	ppb	2024/6/22 06:00	0.6
20	10	淡水	新北市	33	細懸浮微粒	PM2.5	μg/m3	2024/6/22 05:00	7



1. 不同量測變數在同一行！
2. 日期順序怪怪的！

溫度資料 (固定寬度)

hr_tt_1998_72C440.txt									
1	stn_id	yyyymmdd	01	02	03	04	05	06	07
2	72C440	19980101	17.9	17.9	17.9	18.0	17.7	17.8	17.7
3	72C440	19980102	16.5	16.7	16.7	16.5	16.5	16.7	16.7
4	72C440	19980103	18.4	18.4	16.9	16.0	16.0	16.1	16.4
5	72C440	19980104	18.3	17.2	16.8	16.4	16.2	16.3	18.0
6	72C440	19980105	11.9	11.8	12.1	12.0	12.1	12.3	12.8
7	72C440	19980106	14.9	15.1	14.9	14.7	14.7	14.8	14.8
8	72C440	19980107	17.0	16.8	17.0	17.1	17.7	18.0	17.9
9	72C440	19980108	17.4	17.3	17.3	17.4	17.4	18.0	17.9
10	72C440	19980109	17.8	17.1	16.7	16.5	16.4	16.3	16.7
11	72C440	19980110	16.9	17.0	18.0	18.4	18.3	18.1	18.2
12	72C440	19980111	20.2	19.5	19.8	19.6	20.1	20.6	20.5

離子資料 (標題列有2行)

	A	B	C	D	E	F	G	H
1	ELEMENT	H	ELEMENT	C	ELEMENT	O	ELEMENT	Mg
2	[nm]	[Atom/cm3]	[nm]	[Atom/cm3]	[nm]	[Atom/cm3]	[nm]	[Atom/cm3]
3	1.38E+00	1.52E+20	4.77E+00	7.06E+18	3.89E+00	1.75E+19	1.60E+00	2.27E+20
4	7.01E+00	6.77E+18	1.10E+01	2.08E+18	1.01E+01	1.16E+18	4.80E+00	1.78E+20
5	1.25E+01	3.02E+18	1.67E+01	1.28E+18	1.61E+01	5.12E+17	7.99E+00	1.43E+20
6	1.75E+01	2.36E+18	2.24E+01	7.56E+17	2.19E+01	2.91E+17	1.12E+01	8.85E+19
7	2.25E+01	1.98E+18	2.81E+01	5.81E+17	2.77E+01	1.98E+17	1.44E+01	4.86E+19
8	2.75E+01	1.84E+18	3.38E+01	3.78E+17	3.35E+01	1.53E+17	1.76E+01	3.16E+19
9	3.25E+01	2.27E+18	3.95E+01	3.15E+17	3.93E+01	1.27E+17	2.08E+01	2.37E+19
10	3.75E+01	1.79E+18	4.52E+01	2.71E+17	4.50E+01	1.12E+17	2.40E+01	2.06E+19
11	4.26E+01	2.11E+18	5.09E+01	2.34E+17	5.08E+01	1.02E+17	2.72E+01	1.83E+19
12	4.76E+01	2.15E+18	5.66E+01	2.06E+17	5.66E+01	9.83E+16	3.04E+01	1.65E+19
13	5.26E+01	2.21E+18	6.23E+01	1.80E+17	6.24E+01	9.11E+16	3.36E+01	1.53E+19
14	5.76E+01	2.16E+18	6.80E+01	1.55E+17	6.81E+01	8.74E+16	3.68E+01	1.52E+19

可擴展標記語言 (XML)

- XML (Extensible Markup Language)是一種標籤語言, 是一個簡單且非常彈性的文字資料格式
- XML是從標準通用標記式語言 (SGML) 中簡化修改出來的
- XML初期是用於大規模電子出版而設計的文件資料標準
- XML並不是用來編排內容, 而是用來描述資料.
- 它並沒有如同HTML一般的預設標籤, 使用者需要定義描述資料的各種標籤
- XML 的官方 MIME 類型是 application/xml, 副檔名是 .xml
- XML已成為網頁及其他領域中, 進行各種資料交換的重要技術標準
- 可使用 R, Python, Java, .NET 連結 XML

空氣品質指標(AQI)(歷史資料) - XML

- <https://data.gov.tw/dataset/151824>

```
aqx_p_488.xml
1 <?xml version="1.0" encoding="UTF-8"?>
2 <aqx_p_488><data><sitename>屏東(枋山)</sitename><county>屏東縣</county><aqi>26
  </aqi><pollutant></pollutant><status>良好</status><so2>0.1</so2><co>0.11</co><o3>32.8</o3><o3_8hr>
  28.0</o3_8hr><pm10>5</pm10><pm2.5>1</pm2.5><no2>3.1</no2><nox>3.6</nox><no>0.4</no><windspeed>1
  </windspeed><winddirec>85</winddirec><datacreationdate>2023-06-12 10:00
  </datacreationdate><unit></unit><co_8hr>0.1</co_8hr><pm2.5_avg>1</pm2.5_avg><pm10_avg>4
  </pm10_avg><so2_avg>0</so2_avg><longitude>120.651472</longitude><latitude>22.260899
  </latitude><siteid>313</siteid></data><data><sitename>新北(樹林)</sitename><county>新北市
  </county><aqi>38</aqi><pollutant></pollutant><status>良好</status><so2>0.3</so2><co>0.45</co><o3>
  13.4</o3><o3_8hr>6.9</o3_8hr><pm10>18</pm10><pm2.5>6</pm2.5><no2>23.2</no2><nox>35.9</nox><no>12.6
  </no><windspeed>0</windspeed><winddirec>152</winddirec><datacreationdate>2023-06-12 10:00
  </datacreationdate><unit></unit><co_8hr>0.3</co_8hr><pm2.5_avg>7</pm2.5_avg><pm10_avg>24
  </pm10_avg><so2_avg>0</so2_avg><longitude>121.38352778</longitude><latitude>24.94902778
  </latitude><siteid>311</siteid></data><data><sitename>桃園(三民)</sitename><county>桃園市
  </county><aqi>25</aqi><pollutant></pollutant><status>良好</status><so2>0.5</so2><co>0.44</co><o3>
  22.2</o3><o3_8hr>15.2</o3_8hr><pm10>16</pm10><pm2.5>9</pm2.5><no2>15.5</no2><nox>25.2</nox><no>9.6
  </no><windspeed>1</windspeed><winddirec>77</winddirec><datacreationdate>2023-06-12 10:00
```

JSON

- JSON (JavaScript Object Notation)是一種輕量級的資料交換格式
- JSON 源自於JavaScript, JSON不是用於寫程式, 而是儲存與交換資料
- JSON 具有易於人們閱讀, 編寫與其他程式相容性高
 - 網頁應用: JavaScript, Java, Node.js, PHP, C#, R, Python, Julia等
 - 資料庫應用: NoSQL資料庫, 包括文件儲存格式, 例: MongoDB, CouchDB等
- JSON 的官方 MIME 類型是 application/json , 副檔名是 .json 。
- 建立 JSON 字串:
 - 陣列 (array) 可以用中括弧 [] 來寫入資料
 - 物件可 (object) 以用 大括弧{ } 來寫入資料

參考: <https://en.wikipedia.org/wiki/JSON>

JSON的資料型態

- 數值：十進位數，不能有前導0，可以為負數，可以有小數部分。還可以用e或者E表示指數部分。不能包含非數值，例如:不可使用NaN。不區分整數與浮點數。JavaScript用雙精度浮點數表示所有數值。
- 字串：以雙引號 "" 括起來的零個或多個Unicode碼位。支援反斜線開始的跳脫字元序列。
- 布林值：表示為true或者false。
- 值的有序列表（array）：有序的零個或者多個值。每個值可以為任意類型。序列表使用中括號[]。元素之間用逗號,分割。形如：[value, value]
- 物件（object）：無序的「鍵-值對」(key-value pairs)，其中鍵以字串為主。建議但不強制要求物件中的鍵是獨一無二的。物件以大括號{}表示。
例: {key1: value1, key2:value2, ...}。
- null類型：以 null 表示

參考: <https://en.wikipedia.org/wiki/JSON>

臺灣地區人工魚礁區範圍 - JSON

- <https://data.gov.tw/dataset/49099>

```
[
  {
    "field001": "基隆市",
    "field002": "望海巷人工魚礁禁漁區",
    "field003": "N25°08'36\""\",E121°48'18\""\",
    "field004": "26M",
    "field005": "88/12/27",
    "field006": "半徑0.5浬範圍內",
    "field007": "WGS-84"
  },
  {
    "field001": "基隆市",
    "field002": "大武崙人工魚礁禁漁區",
    "field003": "N25°10'45\""\",E121°42'40\""\",
    "field004": "20M",
    "field005": "88/12/27",
    "field006": "半徑0.5浬範圍內",
    "field007": "WGS-84"
  },
]
```

5.資料剖析、解譯與洞察力

資料剖析 (Data Analytics)

- 資料剖析是使用工具和流程來整合和分析企業資料集。
- 資料剖析工具可以結合多個異質來源資料集。
- 資料剖析的成果是回答特定問題、發現新的問題與發現新洞察力。
- 資料剖析幫助企業做出更好的資料驅動決策。

• 技巧

- 關係：正相關、負相關、非線性關係
- 趨勢：上升、下降
- 週期：日、週、月、季、年
- 異常：品質管理、管制界限
- 樣式(Patterns)：綜合上述所有技巧

資料剖析四大類型

從了解過去 → 探索原因 → 預測未來 → 建議行動，驅動更智慧的決策

1. 描述性分析 (Descriptive analytics)

使用歷史資料分析，
目的是理解過去的事件。



- 資料剖析需要編譯資料、識別模式以及深入了解過去的事件，或從過去的事件中學習隱藏在資料背後的潛在知識。

 **問題：發生了什麼事？**
例：銷售額去年同期成長了 15%。

2. 診斷分析 (Diagnostic analytics)

診斷分析深入研究數據，
以確定特定事件背後的原因。



- 涉及識別根本原因、確定相關性並揭示不同變數之間的關係。

 **問題：為什麼會發生？**
例：行銷活動導致銷售額成長。

3. 預測分析 (Predictive analytics)

預測分析使用統計演算法和
歷史資料來預測未來的模式或事件。



- 目標是預測未來事件並評估各種場景的機率。
- 預測分析使用線性迴歸或邏輯斯迴歸模型等演算法。

 **問題：未來會發生什麼？**
例：預測下季銷售額將成長 10%。

4. 規範性分析 (Prescriptive analytics)

規範性分析不僅可以預測未來結果，
還可以推薦具體的決策行動。



- 使用最佳化和模擬技術來確定實現預期結果的最佳行動方案。

 **問題：我們應該怎麼做？**
例：建議增加此產品的庫存與推廣。

潛在知識

 **核心價值：** 資料剖析由淺入深，幫助組織從過去的經驗中學習，理解原因，預測未來，並做出最佳決策，創造更大價值。

資料解譯(Data Interpretation)

- 資料視覺化: Power BI, Tableau, Python, R, SPSS, SAS, MATLAB
- Excel
 - MID, VLOOKUP函數, 樞紐分析
 - 迴歸: https://youtu.be/i5_urp8XzEs
- 直方圖、長條圖、統計檢定 (t-test)、變異數分析 (ANOVA)
- 分類 (Classification)
- 預測 (Prediction)
- 集群 (Clustering)
- 關聯規則 (Association Rules)
- 類神經網路 (Neural Network, NN) ...

0.0375 解譯

洞察力 (Insights)

- 洞察力(見解)表示對於人、事或事物的深刻理解。
- 在資料和分析的背景下，洞察力表示資料分析人員或業務使用者發現以下二項事物：
 - 新的資料模式
 - 以前不知道的變數之間關係
- 洞察力須轉換為**決策執行**。
- 依據執行結果進行**優化處理或改善**。

謝謝您的聆聽

Q & A



李明昌

alan9956@gmail.com

<http://rwepa.blogspot.tw/>